



BURSA ULUDAĞ ÜNİVERSİTESİ
İNEGÖL İŞLETME FAKÜLTESİ
YÖNETİM BİLİŞİM SİSTEMLERİ BÖLÜMÜ

BİLGİSAYARLI GÖRÜ VE MAKİNE ÖĞRENMESİ
TABANLI
GERÇEK ZAMANLI EGZERSİZ FORM ANALİZİ
VE
KİŞİSEL PERFORMANS REHBERLİK SİSTEMİ

LİSANS TEZİ

Furkan AKDEMİR
132230044

Danışman: Prof. Dr. Melih ENGİN

Bursa, 2026

ÖZET

Bilgisayarlı Görü ve Makine Öğrenmesi Tabanlı Gerçek Zamanlı Egzersiz Form Analizi ve Kişisel Performans Rehberlik Sistemi

Bu çalışmada egzersiz yapan bireylerin hareket kalitesini profesyonel bir antrenöre başvurmadan gerçek zamanlı izleyip geliştirebilmelerine olanak tanıyan, veri odaklı ve modüler bir bilgisayarlı görü sistemi tasarlanmış ve Python ekosistemi üzerinde çalışır hâle getirilmiştir. Google'ın BlazePose mimarisine dayanan MediaPipe Pose kütüphanesi, standart bir web kamerasından saniyede 30'un üzerinde karede 33 eklem noktasını çıkarabilmekte ve GPU gerektirmemektedir; 480×270 çözünürlükte yürütülen pose işleme 1280×720 ekran çıkışıyla eş zamanlı çalışmakta, böylece görüntü donması yaşanmamaktadır. Sistem yedi birbirinden bağımsız modülden oluşmaktadır: egzersiz form analiz motorları, makine öğrenmesi sınıflandırıcısı, vücut yağ tahmini, güç profili, beslenme takibi, ilerleme kaydedicisi ve görsel/sesli geri bildirim katmanı. Veri hattı, YouTube'dan yt-dlp ile derlenen 652 egzersiz videosunu işleyerek medyan-kesişim tabanlı adaptif tekrar tespiti yöntemiyle 19 egzersiz kategorisinde 1.139 etiketli tekrar üretmiştir. Her tekrar 40 boyutlu bir özellik vektörüyle temsil edilmektedir; bu vektör sekiz eklem açısının istatistiksel özetleri (32 özellik), sol-sağ simetri ölçütleri (4 özellik) ve hareket aralığı göstergelerinden (4 özellik) oluşmaktadır. `class_weight='balanced'` ve `n_estimators=300` ile yapılandırılan Random Forest sınıflandırıcısı 19 modelin ortalamasında yüzde 76,1 test doğruluğu sağlamıştır. Form analizinin ötesinde sistem; 74.511 kayıtlık NHANES, ANSUR II ve Kaggle verisiyle eğitilmiş, test MAE'si 3,7 yüzde puan olan Gradient Boosting vücut yağ tahmin modeli; 1,3 milyon OpenPowerlifting yarışma kaydından türetilen güç persentil hesaplayıcısı; 455.100 USDA kaydına ek olarak 1.357 Türkiye'ye özgü gıda kaydını barındıran beslenme takip modülü ve JSON tabanlı antrenman ilerleme kaydedicisiyle bütüncül bir performans rehberliği sunmaktadır. Tüm bileşenler tek bir uygulama çatısında birleştirilmiş; düşük donanım gereksinimi ve açık kaynak kütüphane yığını sayesinde bireysel spor senaryolarına uyarlanabilir bir ekosistem oluşturulmuştur.

Anahtar Kelimeler: Bilgisayarlı Görü, Egzersiz Form Analizi, Makine Öğrenmesi, MediaPipe, Performans Takibi

ABSTRACT

Real-Time Exercise Form Analysis and Personal Performance Guidance System Based on Computer Vision and Machine Learning

Poor exercise technique accounts for a large share of weight-training injuries, yet qualified coaching remains out of reach for most recreational athletes due to cost and availability constraints. This thesis describes the design and implementation of a modular, data-driven computer vision platform that delivers real-time exercise form feedback via a standard laptop camera, requiring no dedicated hardware or subscription service. The system comprises seven loosely coupled modules: a rule-based form analysis engine covering 19 exercises, a machine learning classifier, a body fat estimator, a strength profiler, a nutrition tracker, a session progress recorder, and a visual/audio feedback layer; modules communicate only through a shared configuration file and JSON user records, so any single component can be disabled without breaking the rest of the application. Skeleton extraction relies on Google's MediaPipe Pose library (BlazePose, model_complexity=0), which outputs 33 body landmarks at over 30 frames per second; processing runs at 480x270 while display output stays at 1280x720, with PoseWorker, BodyWorker, and GestureWorker threads running concurrently to prevent frame drops. Training data was collected by downloading 652 exercise videos from YouTube using yt-dlp and automatically segmenting 1,139 labeled repetitions across 19 exercise categories via a median-crossing adaptive algorithm, without any manual frame annotation. Each repetition is encoded as a 40-dimensional feature vector — 32 statistical summaries of eight joint angles, 4 left-right symmetry metrics, and 4 motion range indicators — and classified by a Random Forest (n_estimators=300, class_weight=balanced) that averaged 76.1 percent test accuracy across 19 models. The body fat module was trained on 74,511 NHANES, ANSUR II, and Kaggle records using a Gradient Boosting Regressor pipeline and achieved a test MAE of 3.7 percentage points. The strength percentile calculator derives competition norms from 1.3 million raw OpenPowerlifting entries; the nutrition module combines 455,100 USDA records with 1,357 Turkey-specific items from BEBIS and Open Food Facts. All components share a single JSON-based user profile and progress log, keeping installation dependencies minimal and enabling multi-user operation without any external database.

Keywords: Computer Vision, Exercise Form Analysis, Machine Learning, MediaPipe, Performance Tracking

İÇİNDEKİLER

ÖZET	i
ABSTRACT	ii
İÇİNDEKİLER	iii
TABLolar	v
ŞEKİLLER	vi
1. GİRİŞ	1
1.1. Problem Durumu ve Motivasyon	1
1.2. Araştırma Soruları ve Hedefler	2
1.3. Çalışmanın Kapsamı	3
2. TEORİK ARKA PLAN	4
2.1. İnsan Pozu Tahmini	4
2.2. BlazePose ve MediaPipe Çerçevesi	5
2.3. Eklem Açısı Hesabı ve Biyomekanik	6
2.4. Makine Öğrenmesi: Random Forest	7
2.5. Vücut Kompozisyonu Tahmini	7
2.6. Güç Normalizasyonu ve Dots Skoru	8
2.7. Çok İş Parçacıklı Sistem Tasarımı	9
3. LİTERATÜR TARAMASI	10
4. YÖNTEM	13
4.1. Sistem Mimarisine Genel Bakış	13
4.2. Veri Toplama ve İşleme Pipeline'ı	14
4.3. İskelet Çıkarımı ve Özellik Hesaplama	16
4.4. Kural Tabanlı Form Analiz Motorları	17
4.5. Makine Öğrenmesi Sınıflandırıcısı	18
4.6. Tamamlayıcı Modüller	19
4.6.1. Vücut Yağ Tahmini	19
4.6.2. Güç Profili ve Dots Skoru	21
4.6.3. Beslenme Takip Modülü	22
4.6.4. İlerleme Kaydedicisi	23
4.6.5. Kullanıcı Profil Sistemi	24
4.6.6. Kullanıcı Arayüzü ve Geri Bildirim	24
5. BULGULAR	25
5.1. Veri Seti İstatistikleri	25
5.2. Model Performans Sonuçları	26

5.3. Sistem Performansı	28
5.4. Vücut Yağ ve Güç Profili Değerlendirmesi	28
6. TARTIŞMA VE SONUÇ	30
6.1. Bulgular Üzerine Değerlendirme	30
6.2. Literatürle Karşılaştırma	31
6.3. Sınırlılıklar	32
6.4. Gelecek Çalışmalar	32
6.5. Sonuç	33
KAYNAKÇA	34
EKLER	37

TABLÖLAR

Tablo 1. Egzersiz form analizi literatürü karşılaştırma tablosu	12
Tablo 2. Seçili egzersizler için analiz parametreleri	17
Tablo 5. Vücut yağ modeli veri kaynaklarının dağılımı	19
Tablo 3. Egzersiz başına veri seti istatistikleri	25
Tablo 4. Egzersiz modeli test doğrulukları	26

ŞEKİLLER

Şekil 1. Sistem modül mimarisi — yedi bileşen ve veri akışı	13
Şekil 2. Veri işleme pipeline akışı — videodan CSV'e	15
Şekil 3. HUD ekranı dört panel düzeni	24

1. GİRİŞ

1.1. Problem Durumu ve Motivasyon

Dünya genelinde spor salonu üyeliği sahipliği son on yılda önemli ölçüde artmış; yalnızca Avrupa'da kayıtlı spor salonu üye sayısı 2022 itibarıyla 60 milyonu aşmıştır (EuropeActive, 2022). Bu büyüme, sağlıklı yaşam bilincinin ve egzersizin kronik hastalık riskini azaltıcı etkisine dair kanıtların giderek yaygınlaşmasıyla paralel bir seyir izlemektedir. Bununla birlikte egzersiz katılımcılarının büyük çoğunluğu amatör düzeydedir ve uygun teknikle ilgili temel eğitimden yoksundur. Amerikan Ortopedi Cerrahları Akademisi'nin (AAOS) verilerine göre ağırlık antrenmanı kaynaklı yaralanmaların yüzde 40 ila 70'i hatalı hareket mekaniğine bağlıdır (Kerr vd., 2010). Kişisel antrenör bu açığı kapatabilecek en etkili çözüm olmakla birlikte yüksek maliyeti, sınırlı erişimi ve fiziksel mekân bağımlılığı nedeniyle kullanıcıların büyük çoğunluğuna ulaşamamaktadır.

Öte yandan son birkaç yılda iki şey değişti. Birincisi, web kamerası artık neredeyse her dizüstü bilgisayarda standart; çözünürlük ve kare hızı açısından birkaç yıl öncesine kıyasla çok daha iyi. İkincisi, MediaPipe ve benzeri kütüphaneler sayesinde gerçek zamanlı iskelet tespiti artık doktora tezi değil, lisans tezi ölçeğinde yapılabilir hâle geldi. Bu çalışma tam olarak o fırsatı değerlendirmeye çalışıyor: bir Yönetim Bilişim Sistemleri öğrencisinin mevcut açık kaynak araçlarla ne kadar işlevsel bir egzersiz koçluğu sistemi kurabileceğini görmek.

Mevcut ticari alternatifler bu boşluğu ancak kısmen doldurmaktadır. Apple Watch ve Garmin gibi giyilebilir cihazlar tekrar sayma ve kalp atış hızı gibi temel metrikleri izleyebilmekte, ancak form kalitesi değerlendirmesi yapamamaktadır. Peloton ve Mirror gibi interaktif fitness platformları ise rehberli video içerik sunmakla birlikte kullanıcının bireysel biyomekaniğine uyarlanmış gerçek zamanlı düzeltme yapamamaktadır. OpenCV ve MediaPipe gibi açık kaynak araçların olgunlaşmasıyla bu boşluk artık araştırma düzeyinde değil, lisans tezi ölçeğinde bile adreslenebilecek hâle gelmiştir.

1.2. Araştırma Soruları ve Hedefler

Bu çalışmanın temel araştırma sorusu şöyle ifade edilmektedir: Standart bir RGB kameradan elde edilen ham görüntü akışı, bir veri işleme hattı, biyomekanik kural motoru ve makine öğrenmesi sınıflandırıcısı aracılığıyla işlenerek egzersiz yapan bir bireye antrenör düzeyinde gerçek zamanlı form geri bildirimi sunulabilir mi? Bu

soruyu yanıtlamak amacıyla çalışma üç alt hedef belirlemiştir.

Birinci hedef, büyük ölçekli video verisi üzerinde çalışan, insan müdahalesi gerektirmeyen otomatik bir etiketleme ve özellik çıkarma hattı tasarlamaktır. İkinci hedef, kural tabanlı anlık geri bildirim ile tekrar sonrası makine öğrenmesi tahminin bir arada çalıştığı hibrit bir form analiz mimarisi kurmak; bu sayede her iki yaklaşımın güçlü yanlarından yararlanmaktır. Üçüncü hedef ise form analizini vücut yağ tahmini, güç profili ve beslenme takibiyle bütünleştirerek kullanıcıya salt teknik düzeltmenin ötesinde kişiselleştirilmiş bir rehberlik ekosistemi sunmaktır.

Çalışma kapsamında aşağıdaki alt sorular ele alınmıştır: (1) Medyan-kesişim tabanlı adaptif tekrar tespiti, sabit açı eşiklerine dayanan geleneksel yöntemlere kıyasla farklı kamera açıları ve kullanıcı vücut oranlarında daha tutarlı sonuç üretebilir mi? (2) Egzersiz başına ortalama 60 etiketli tekrarlar eğitilen Random Forest modelleri klinik düzeyde kullanılabilir bir doğruluğa ulaşabilir mi? (3) 74.511 kişilik nüfus verisiyle eğitilen vücut yağ tahmini modeli, pahalı klinik ölçüm yöntemlerine makul bir alternatif olabilir mi?

1.3. Çalışmanın Kapsamı

Bu tez, spor salonu türü ağırlık antrenmanı egzersizleriyle sınırlıdır; kardiyovasküler egzersizler, yoga ve takım sporu hareketleri kapsam dışında tutulmuştur. Sistem, tek kullanıcı ve kapalı mekân senaryosu için optimize edilmiştir. Veri toplama aşamasında 19 egzersiz kategorisi kullanılmış; silinmiş modeller (push_up ve russian_twist) tek sınıf sorunu nedeniyle kapsam dışına alınmıştır. Klinik doğrulama çalışması bu tezin kapsamı dışındadır; bildirilen doğruluk değerleri etiketleme sürecinde kullanılan YouTube veri setine özgüdür ve bağımsız kullanıcı testleriyle doğrulanmamıştır.

2. TEORİK ARKA PLAN

2.1. İnsan Pozu Tahmini

İnsan pozu tahmini (human pose estimation), bir görüntü ya da video karesindeki vücudun eklem noktalarını — omuz, dirsek, bilek, kalça, diz, ayak bileği — piksel koordinatlarında bulmayı hedefler. Konu 1970'lerden bu yana araştırılmaktadır; ancak alandaki asıl sıçrama, Krizhevsky vd.'nin (2012) ImageNet yarışmasını derin evrişimli ağlarla kazanmasıyla birlikte gerçekleşmiştir. O tarihten itibaren el yapımı özellik mühendisliği yerini uçtan uca öğrenmeye bırakmıştır.

Literatürdeki yaklaşımlar iki ana kolda toplanmaktadır. Birinci kolda model her eklem için bir olasılık ısı haritası üretir; eklem tahmini konumu bu haritanın tepe noktasından okunur. Newell vd.'nin (2016) Yığılmış Kum Saati Ağı (Stacked Hourglass) bu yaklaşımın mihenk taşı sayılır. İkinci kolda ise ağ koordinatları doğrudan sayı olarak çıktılar; Sun vd.'nin (2019) geliştirdiği HRNet mimarisi yüksek çözünürlüklü temsili paralel akışlarda koruyarak her iki yaklaşımın güçlü yanlarını bir araya getirmiştir.

2.2. BlazePose ve MediaPipe Çerçevesi

BlazePose (Bazarevsky vd., 2020), Google'ın telefon kameralarında çalışmak üzere tasarladığı hafif bir poz tahmin modelidir. Mimaride iki aşama art arda çalışır: önce dedektör kişinin varlığını ve kaba konumunu belirler; ardından landmarker bu bölgeyi kırıp 33 eklem noktasının normalize 2D/3D koordinatlarını ve görünürlük skorlarını hesaplar. Görünürlük skoru 0 ile 1 arasında bir değerdir; bu çalışmada 0,4'ün altı güvenilir kabul edilerek hesaplamadan dışlanmıştır. MediaPipe (Lugaresi vd., 2019), BlazePose'u ve diğer algı modellerini birbirine bağlayan açık kaynak pipeline çerçevesidir.

2.3. Eklem Açısı Hesabı ve Biyomekanik

Bir egzersizin form kalitesini sayısallaştırmanın en doğrudan yolu eklem açılarını ölçmektir. Bu çalışmada açı, üç landmark noktasının (A, B, C) oluşturduğu vektörler arasındaki açı olarak tanımlanmaktadır: $\theta = \arccos((BA \cdot BC) / (|BA| \times |BC| + 1e-8))$. Epsilon terimi, landmark'ların üst üste geldiği durumlarda sıfıra bölme hatasını önlemek için eklenmiştir. Hesaplama ilk bakışta basit görünse de gerçek zamanlı uygulamada iki sorun çıkmaktadır: birincisi, MediaPipe zaman zaman bir eklem noktasını yanlış konuma yerleştirebilmektedir; ikincisi, kullanıcının kameraya açısına bağlı olarak bazı eklemler kısmi ya da tamamen görünmez hâle gelmektedir.

Visibility skoru 0,4'ün altında kalan herhangi bir landmark içeren açı hesaba katılmamakta; bu eşiğin 0,5'e çıkarılması test sırasında lateral_raise gibi omuz ağırlıklı egzersizlerde veri kaybına yol açtığından 0,4'te bırakılmıştır. Hareket aralığı (ROM) ise tekrar boyunca kaydedilen maksimum ve minimum açı farkı olarak hesaplanmaktadır.

2.4. Makine Öğrenmesi: Random Forest

Breiman (2001), karar ağaçlarının tek başına yüksek varyanslı çıktılar ürettiğini gözlemleyerek bootstrap örneklemesiyle büyütülen yüzlerce ağacın oylamayla birleştirildiği Random Forest'i önermiştir. Bu çalışmada algoritmayı tercih eden üç pratik neden vardır. Birincisi, class_weight='balanced' seçeneği sınıf dengesizliğini (örneğin shoulder_press'te 5 doğru / 56 yanlış) otomatik ağırlıklandırmayla gidermektedir. İkincisi, predict_proba() ile her tahmine güven skoru eşlik etmekte; düşük güvenli (< 0,55) tahminler HUD'da ayrıca işaretlenmektedir. Üçüncüsü, n_jobs=-1 ile tüm CPU çekirdeklerini kullanarak eğitim süresi kısalmaktadır. Nihai yapılandırma: n_estimators=300, min_samples_leaf=3.

2.5. Vücut Kompozisyonu Tahmini

Vücut yağ oranını doğru ölçmenin iki altın standardı DEXA taraması ve su altı tartımıdır; her ikisi de özel klinik donanım gerektirir ve sıradan kullanıcıya erişilebilir değildir. Daha ucuz alternatifler — BKİ, deri kıvrımı, biyoelektrik impedans — tek bir ölçüme dayandığından hataya açıktır. Bu çalışmada benimsenen yaklaşım, boy-kilo-yaş-cinsiyet temelini kamera silüetiyle zenginleştiren bir özellik vektörü üzerinde Gradient Boosting Regressor çalıştırmaktır. GBR'nin artıksal öğrenme mekanizması, birbiriyle korelasyonlu antropometrik ölçümler arasındaki doğrusal olmayan ilişkileri yakalamada basit regresyon modellerinden belirgin biçimde daha başarılıdır. Ayrıca SimpleImputer ile eksik ölçümler medyanla tamamlandığından kullanıcının yalnızca boy-kilo-yaş girmesi bile çalışan bir tahmin üretmektedir.

2.6. Güç Normalizasyonu ve Dots Skoru

70 kg'lık bir sporcunun 150 kg squat yapması mı daha etkileyici, yoksa 100 kg'lık birinin 180 kg yapması mı? Bu soruyu yanıtlamak için vücut ağırlığından bağımsız bir normalizasyon katsayısı gerekir. Wilks katsayısı uzun yıllar bu amaçla kullanılmıştır; ancak OpenPowerlifting topluluğu 2019'da yüksek vücut ağırlığı kategorilerindeki adaletsiz eğriyi düzelterken Dots formülünü önermiştir. $Dots = 500 / f(bw) \times toplam_kg$ formülünde payda $f(bw)$, erkekler için dördüncü dereceli bir polinomdur. Sisteme bu formülü entegre ederken ilk hesaplamada hata yapıldı:

polinomun katsayıları OpenPowerlifting wiki sayfasından elle girildiğinden bir negatif işaret kaçırılmıştı ve 80 kg altı için Dots değerleri hatalı çıkıyordu. Kaynaktaki katsayılar tek tek doğrulandıktan sonra düzeltildi; bu nedenle tezdeki Dots değerleri nihai doğrulanmış formüle aittir.

2.7. Çok İş Parçacıklı Sistem Tasarımı

Ana kamera döngüsü her kareyi hem ekranda göstermek hem de MediaPipe'a işletmek hem de el jestlerini okumak zorundadır. Bunları tek thread'de sırayla yapmak denemeye değer ama çalıştırmaya değmez; test sırasında tüm işlemi tek döngüde yaptığımızda kare hızı 8-10 fps'ye düşüyordu. Çözüm klasik üretici-tüketici deseni oldu: PoseWorker, BodyWorker ve GestureWorker adlı üç daemon thread Python queue'larıyla kamera döngüsünden bağımsız çalışmakta; threading.Lock ile paylaşılan değişkenlere erişim güvence altına alınmaktadır. Her thread 480×270 girdi alır; işlenmiş sonuçlar bir sonraki kare çizilmeden önce ana döngüye aktarılır. Bu yapı standart donanımda 30 fps'nin korunmasını sağlamaktadır.

3. LİTERATÜR TARAMASI

Egzersiz form analizi ve hareket kalitesi değerlendirmesi akademik literatürde üç ana koldan ele alınmaktadır: (1) özel donanım (Kinect, IMU) tabanlı yaklaşımlar, (2) RGB kamera ve poz tahmin modeli tabanlı yaklaşımlar, (3) giyilebilir sensör tabanlı yaklaşımlar. Bu bölüm, her koldan öne çıkan çalışmaları değerlendirmekte ve mevcut çalışmanın konumunu belirlemeyi amaçlamaktadır.

Özel donanım tabanlı çalışmalar arasında en kapsamlı veri setini sunan KIMORE (Capecci vd., 2018) dikkat çekmektedir. Microsoft Kinect RGB-D sensörüyle kayıt altına alınan 78 katılımcının beş fizik tedavi egzersizini gerçekleştirmesinden oluşan bu veri seti, klinik hareket puanlamasıyla eşleştirilmektedir. Mevcut çalışma bu kısıtı standart RGB kameraya yönelerek aşmaktadır.

Shotton vd. (2011), Microsoft'un Kinect'i için temel algoritmik katkıyı sunmuştur. Rastgele karar ağacı tabanlı bu yaklaşım, derinlik görüntülerinden milisaniyeler içinde insan vücut parçalarını sınıflandırabilmektedir. RGB kamera tabanlı hareket kalitesi değerlendirmesinde Pirsivash ve Ramanan (2014), profesyonel hakem puanlamasını hedef alarak çeşitli sporlarda otomatik hareket kalitesi derecelendirmesi yapmıştır. Liao vd. (2020), squat egzersizinde açı sapmasını ölçmek için OpenPose tabanlı bir sistem geliştirmiş; 8 katılımcı üzerinde yaptıkları test çalışmasında yüzde 85 uyum bildirmiştir.

Dang vd. (2022), 2012-2022 döneminde yayımlanan 2B insan pozu tahmin yöntemlerini kapsamlı biçimde inceleyen bir derleme çalışması sunmuş; yöntemleri ısı haritası tabanlı ve regresyon tabanlı olarak sınıflandırarak her kategorinin güçlü ve zayıf yanlarını karşılaştırmalı olarak ortaya koymuştur. Kok vd. (2022), MediaPipe Pose kullanarak ev ortamında squat ve lunge analizini gerçekleştirmiş; 10 katılımcılı ön çalışmalarında uzman değerlendirmesiyle ortalama yüzde 79 uyum bildirmiştir.

Türkiye'de YBS ve bilgisayar mühendisliği perspektifinden yürütülmüş kamera tabanlı egzersiz form analizi çalışmalarının sayısı oldukça sınırlıdır. YÖK Ulusal Tez Merkezi veritabanında gerçekleştirilen taramada bu konuyu doğrudan ele alan bir tez kaydına ulaşılamamıştır. Bu durum, mevcut çalışmanın yerel literatürdeki boşluğu doldurma ve gelecek araştırmalara referans oluşturma potansiyelini güçlendirmektedir.

Tablo 1. Egzersiz form analizi literatürü karşılaştırma tablosu

Çalışma	Donanım	Kapsam	Gerçek Zamanlı	ML Modeli
Pirsiavash & Ramanan (2014)	RGB Kamera	Genel spor	Hayır	SVM
Shotton vd. (2011)	Kinect RGB-D	Genel poz	Evet	Karar Ağacı
Capecci vd. (2018)	Kinect RGB-D	Rehabilitasyon	Hayır	Yok
Liao vd. (2020)	RGB Kamera	Squat	Evet	Yok (kural)
Dang vd. (2022)	—	Derleme	Hayır	Çeşitli
Kok vd. (2022)	RGB Kamera	Squat/Lunge	Evet	Yok (kural)
Bu Çalışma	RGB Kamera	19 Egzersiz	Evet	Random Forest

Tablo 1'den görüldüğü üzere, tek kamera kullanarak 19 farklı egzersizi gerçek zamanlı hem kural tabanlı hem de makine öğrenmesi sınıflandırmasıyla değerlendiren bir çalışma literatürde yer almamaktadır.

4. YÖNTEM

4.1. Sistem Mimarisine Genel Bakış

Sistem, birbirine gevşek bağlı yedi işlevsel modülden oluşmaktadır. Her modül kendi alt dizininde bağımsız Python paketleri olarak yapılandırılmış; modüller arası bağımlılık yalnızca config.py sabitleri ve kullanıcı_verisi/ klasöründeki JSON dosyaları üzerinden kurulmaktadır. Ana uygulama döngüsü main.py'de tanımlıdır; bu dosya kamera akışını PoseWorker thread'ine yönlendirerek tüm modülleri tek bir ekran döngüsünde orchestrate etmektedir. Kamera çözünürlüğü 1280×720 olarak tutulurken pose işleme 480×270'de gerçekleştirilmekte; bu ayırım sayesinde standart donanımda 30 fps akıcılık korunmaktadır. Şekil 1'de sistemin genel modül mimarisi ve bileşenler arası veri akışı gösterilmektedir.

main.py — Ana Uygulama Döngüsü (Kamera + Tuş + Ekran)						
PoseWorker (iskelet)		BodyWorker (segmentasyon)		GestureWorker (el jesti)		
exercises/ 19 form motoru	ml/ RF sınıflandırıcı	bodyfat/ yağ tahmini	strength/ güç profili	nutrition/ beslenme	progress/ ilerleme	feedback/ HUD + ses

Şekil 1. Sistem modül mimarisi — yedi bileşen ve veri akışı

4.2. Veri Toplama ve İşleme Pipeline'ı

Etiketli egzersiz verisi üretmek için tamamen otomatik, uçtan uca bir veri işleme hattı tasarlanmıştır. Veri derleme sürecinde her egzersiz için İngilizce arama terimleri oluşturulmuş; "proper form", "correct technique", "common mistakes" anahtar sözcükleri birleştirilerek hem doğru hem de hatalı form örneklerini barındıran kanallar hedeflenmiştir. Bu strateji, aynı video kaynağından hem "correct" hem "wrong" etiketli tekrar çıkarmayı mümkün kılmıştır. Toplam 652 video 21 egzersiz kategorisinde derlenmiştir; push_up ve russian_twist kategorileri etiketleme sonrasında tek sınıf (yalnızca "correct") içerdiğinden kapsam dışına alınmış, 19 egzersiz kalıcı olarak benimsenmiştir.

Video indirme altyapısı olarak yt-dlp kullanılmıştır. Bazı büyük fitness kanalları bot trafiğini engellemek amacıyla HTTP 429 hataları döndürdüğünden --sleep-requests

1.0 ve --sleep-interval 2 parametreleri eklenerek istek hızı düşürülmüştür. İndirilen videolar 1080p veya mevcut en yüksek çözünürlükte kaydedilmiş; video başına ortalama dosya boyutu 180 MB civarında seyretmiştir. 652 videonun tamamı yaklaşık 14 saatlik toplu işlemle ml/video_miner.py modülü aracılığıyla işlenmiştir. Tekrar tespitinde geliştirilen medyan-kesişim tabanlı adaptif algoritma, son 60 karenin medyanını dinamik eşik olarak güncelleme; birincil açı bu eşiği iki kez (aşağıdan yukarıya ve yukarıdan aşağıya) geçtiğinde bir tekrarı tamamlanmış saymaktadır. Bu yaklaşım, sabit açı eşiği kullanan yöntemlerin farklı kamera açıları ve boy oranlarında yaşadığı hassasiyet sorununu belirgin ölçüde azaltmıştır.

Video işleme hattının adım adım akışı şöyledir: ham video OpenCV VideoCapture nesnesiyle açılır; gereksiz hesaplamadan kaçınmak amacıyla her üçüncü kare alınır ve BGR'den RGB'ye dönüştürülerek MediaPipe Pose API'ye iletilir. Başarılı iskelet tespitinde landmarks_to_angles() işlevi çağrılarak sekiz eklem açısı hesaplanır ve anlık açı sözlüğüne eklenir. Egzersiz motorunun analyze() metodu bu sözlüğü oylayarak faz bilgisini (up/down) günceller; medyan eşik kontrolü iki kesişim sayıldığında _flush_rep() devreye girer ve o tekrara ait tüm frame açıları veri setine CSV satırları olarak yazılır. Veri kalitesi güvencesi için hatta dört katmanlı filtreleme uygulanmıştır: (1) visibility skoru 0,40'ın altındaki kareler işlenmez; (2) 10 kareden kısa tekrarlar atılır; (3) oyların yüzde 60'ından azı "correct" ise tekrar otomatik olarak "wrong" olarak etiketlenir; (4) sınıf başına beşten az örnek içeren egzersizler model eğitiminden çıkarılır. Bu filtreler sonucunda hammadde 1.139 kullanılabilir tekrara indirilmiştir.

Ham Video (652 dosya, ~180 MB/video, toplam ~117 GB)			
1. VideoCapture (her 3. kare)	2. BGR→RGB dönüşüm	3. MediaPipe Pose API	4. landmarks → angles()
5. Faz tespiti (up/down)	6. Medyan eşik kontrolü	7. Tekrar sayacı	8. _flush_rep() → CSV satırı
Filtre 1: visibility < 0.40 → at	Filtre 2: < 10 kare → at	Filtre 3: oy < %60 → wrong	Filtre 4: < 5 örnek → çıkar
1.139 kullanılabilir tekrar (655 correct / 484 wrong)			

Şekil 2. Veri işleme pipeline akışı — videodan etiketli CSV'ye

4.3. İskelet Çıkarımı ve Özellik Hesaplama

MediaPipe Pose API şu üç parametreyle yapılandırılmıştır: model_complexity=0 (hız-doğruluk dengesini standart donanım koşullarında optimize eden hafif model), min_detection_confidence=0.6, min_tracking_confidence=0.5. Özellik vektörü 40 boyuttan oluşmaktadır. Birinci grup: sekiz temel açının tekrar boyunca minimum, maksimum, ortalama ve standart sapması (32 özellik). İkinci grup: simetri ölçütleri (4 özellik). Üçüncü grup: ROM, maksimum hız, faz oranı ve normalize süre (4 özellik). Minimum açı tam kontraksiyonu; maksimum açı tam uzanmayı; standart sapma hareket tutarlılığını kodlar. Simetri ölçütleri sol-sağ asimetriyi ölçmekte; 15°'nin üzerindeki asimetri yaralanma riskini artırmaktadır.

4.4. Kural Tabanlı Form Analiz Motorları

Sistemdeki 19 egzersiz için bağımsız analiz motorları oluşturulmuştur. Tüm motorlar exercises/base_exercise.py'daki BaseExercise soyut sınıfından türemekte ve analyze(landmarks, width, height) → FormResult arayüzünü uygulamaktadır. Hata yaralanma riskiyle doğrudan ilişkili sapmalara, uyarı ise etkinliği düşüren ancak acil tehlike oluşturmeyen sapmalara karşılık gelir.

Tablo 2. Seçili egzersizler için analiz parametreleri

Egzersiz	Birincil Açı	Zirve (°)	Dip (°)	Ek Kural
Biceps Curl	Sol dirsek	55	150	Gövde eğilimi < 0.09
Triceps Ext.	Sol dirsek	150	60	Dirsek sabit
Shoulder Press	Sol dirsek	160	80	Bilek hizası
Lateral Raise	Sol omuz	65	30	Dirsek bükülmesi
Pec Fly	Sol dirsek	100	175	Simetri < 15°
Bench Press	Sol dirsek	80	155	Flare açısı < 75°
Squat	Sol diz	85	160	Diz-parmak hizası
Deadlift	Sol diz	90	160	Sırt duruluğu
Lat Pulldown	Sol dirsek	65	155	Gövde sallanımı
Hip Thrust	Sol kalça	165	100	Kalça uzanması
Leg Extension	Sol diz	165	85	Tam uzanma

4.5. Makine Öğrenmesi Sınıflandırıcısı

ml/trainer.py modülü şu adımları izler: (1) CSV yükleme ve etiket dönüşümü, (2) sınıf başına minimum 5 örnek kontrolü, (3) stratifiye 80/20 bölünme, (4) StandardScaler fit (sadece eğitim kümesine), (5) RandomForestClassifier(n_estimators=300, class_weight='balanced', min_samples_leaf=3) eğitimi, (6) test doğruluğu hesaplama, (7) ml/models/{egzersiz}_form.joblib'e kaydetme. Güven skoru 0,55 eşliğinin altında kaldığında "düşük güven" uyarısı gösterilmektedir.

4.6. Tamamlayıcı Modüller

Temel form analizi altyapısının yanı sıra sistem; vücut kompozisyonu tahmini, güç persentili hesaplama, beslenme takibi, antrenman günlüğü ve kişisel profil yönetimini tek çatı altında birleştiren beş tamamlayıcı modül içermektedir. Bu modüller birbirinden bağımsız Python paketleri olarak tasarlanmış; ortak bağımlılık yalnızca kullanıcı_verisi/ dizinindeki JSON dosyaları üzerinden kurulmuştur. Böylece herhangi bir modül devre dışı bırakıldığında ana form analizi döngüsü kesintisiz çalışmaya devam etmektedir.

4.6.1. Vücut Yağ Tahmini

bodyfat/estimator.py modülü iki ayrı bilgi kaynağını birleştirerek vücut yağ oranı tahmini yapmaktadır: kamera görüntüsünden MediaPipe SegmentationMask aracılığıyla ölçülen silüet genişlikleri ve kullanıcının profilinden alınan antropometrik veriler. Silüet ölçümü için yöntem şu şekilde işler: maske ikili eşiklendikten sonra ($> 0,45$) her yatay satırdaki en soldaki ve en sağdaki piksel koordinatları belirlenir; bel bölgesi için omuz-kalça mesafesinin yüzde 60'ı noktasından üç piksel yukarı-aşağı taranarak medyan genişlik alınır. Ham piksel genişliğini santimetreye çevirmek için kullanıcı boyuna oransal bir ölçek katsayısı uygulanır. Ölçülen piksel genişliği gerçek çevre ölçümüne doğrudan eşit olmadığından NHANES popülasyon verisiyle kalibre edilmiş BMI-bağımlı dönüşüm katsayıları kullanılmaktadır: kalça için $hip_factor = 1,856 + 0,0255 \times BKİ$, bel için $waist_factor = 1,580 + 0,0350 \times BKİ$. Bu katsayılar 68.011 NHANES ölçümünün anlık kamera açısına uyarlanmasıyla türetilmiştir.

Model eğitimi için vücut yağ ölçümüne sahip üç kaynaktan toplamda 74.511 kayıt bir araya getirilmiştir. Bu kaynakların dağılımı Tablo 5'te özetlenmiştir. Eğitim pipeline'ı SimpleImputer(strategy=median) → StandardScaler → GradientBoostingRegressor(n_estimators=300, max_depth=4, learning_rate=0.05, subsample=0.8) adımlarından oluşmaktadır. Eksik ölçümlerin medyanla doldurulması, farklı veri kalitesi senaryolarında (yalnızca boy/kilo biliniyorsa veya

tüm çevre ölçüleri mevcutsa) aynı modelin sorunsuz çalışmasını sağlamaktadır. Test kümesinde elde edilen MAE değeri 3,7 yüzde puandır. Gerçek zamanlı kararlılık için tahminler 25 karelik bir halka tamponda toplanmakta ve kullanıcıya medyan değer gösterilmektedir; bu yöntem anlık görüntü gürültüsünden kaynaklanan $\pm 0,5$ puanlık salınımları bastırmaktadır.

Tablo 5. Vücut yağ modeli veri kaynaklarının dağılımı

Kaynak	Kayıt Sayısı	Ölçüm Türü	Popülasyon
NHANES (2003-2018)	68.011	DXA (altın standart)	ABD genel popülasyon
ANSUR II (2012)	6.068	Antropometri + BKİ tahmini	ABD Ordusu personeli
Kaggle – Extended BF	432	Su altı tartımı	Karma (spor salonu)
TOPLAM	74.511	—	—

Kamera mesafesi yetersiz olduğunda veya maske kalitesi düştüğünde sistem otomatik olarak Deurenberg (1991) fallback formülüne geçmektedir: $\text{yağ_oranı} = 1,20 \times \text{BKİ} + 0,23 \times \text{yaş} - 16,2$ (erkek) veya $- 5,4$ (kadın). Segmentasyon maskesi geçerli olduğu durumlarda hesaplanan değerler; BKİ, bel ve kalça persentilleri NHANES+ANSUR2 norm tablosuna karşı anlık olarak hesaplanmaktadır. Vücut tipi sınıflandırması erkekler için altı aralığa ayrılmıştır: < yüzde 6 Estetik Sporcu, yüzde 6-14 Atletik, yüzde 14-18 Fit, yüzde 18-25 Ortalama, yüzde 25 üstü Yüksek Yağ. Bu eşikler American Council on Exercise (ACE) kategorileriyle örtüşmekte; kadın için aralıklar yaklaşık sekiz puan yukarı kaydırılmaktadır.

4.6.2. Güç Profili ve Dots Skoru

strength/estimator.py modülü kullanıcının squat, bench press ve deadlift kaldırışlarını OpenPowerlifting veri tabanından türetilen norm tablolarıyla karşılaştırarak güç persentilini hesaplamaktadır. OpenPowerlifting, uluslararası powerlifting federasyonlarına ait yarışma kayıtlarını açık kaynak olarak yayımlamaktadır. Ham veride 1,3 milyonun üzerinde tekrar kaydı bulunmaktadır; bu kayıtlar veri seti içinde hem doğal (ekipmansız) hem de teknikli (Squat suit, Bench shirt) sporcuları kapsamaktadır. veri/kondisyon/build_strength_norms.py betiği bu veriyi filtreler: ekipman="Raw" veya "Wraps" olmayan kayıtlar, geçersiz kaldırış değerleri (sıfır veya negatif) ve doping ihlali bulunan sporcular elenmiştir. Kalan kayıtlar cinsiyete ve 5 kg'lık vücut ağırlığı dilimlerine (40-45 kg'dan 155-160 kg'ya kadar) ayrılarak

p10, p25, p50, p75, p90 persentil deęerleri hesaplanmış ve 202 satırlık strength_norms.csv dosyasına özetlenmiştir.

Persentil hesabında ham kaldırış kilogramı deęil Dots skoru kullanılmaktadır. Dots skoru, kaldırış aęırlıęını vücut aęırlıęından baęımsız kılan bir normalizasyon katsayısıdır: $Dots = 500 / f(bw) \times toplam_kg$. Payda $f(bw)$, erkekler için $-0.00000109 \times bw^4 + 0.000739 \times bw^3 - 0.1919 \times bw^2 + 24.09 \times bw - 307.75$ şeklinde tanımlanan dördüncü dereceli bir polinomdur. Bu formül 2019'da OpenPowerlifting topluluęu tarafından Wilks katsayısının yerine önerilmiştir; özellikle yüksek vücut aęırlıęı kategorilerinde daha adil bir karşılaştırma sağladığı gösterilmiştir. Kullanıcının belirlenen vücut aęırlıęı dilimine düşen norm satırında Dots skoru interpolasyonla yerleştirilmekte ve kaçınıcı persentilde olduęu kullanıcı arayüzüne yansıtılmaktadır.

4.6.3. Beslenme Takip Modülü

nutrition/ alt sistemi iki katmandan oluşmaktadır: gıda veritabanı (food_db.py) ve günlük kalori/makro kaydedicisi (tracker.py). Gıda veritabanı, USDA FoodData Central'ın Nisan 2026 sürümünden derlenen 455.100 kayıtlık compact CSV üzerine inşa edilmiştir. Bu kayıtların büyük çoęunluęu (440.450 adet) markalı ürünler olmakla birlikte Türkiye'ye özgü iki ek kaynak da entegre edilmiştir. Birinci ek kaynak, Hacettepe Üniversitesi'nin Besin Bilgi Sistemi'ni (BEBIS) ve TURKKOMP verilerini temel alan 275 adet el yapımı Türk ev yemeęi kayıdır; mercimek çorbası, imam bayıldı, köfte gibi yaygın yemekleri 100 gram başına makro deęerleriyle içermektedir. İkinci ek kaynak, Open Food Facts'tan Türkiye etiketiyle çekilen 1.082 adet paketli ürün kayıdır. Bu iki kaynak birleştirildiğinde veritabanında 1.357 Türk gıdası yer almakta; standart USDA aramaları yetersiz kaldığında öncelikli olarak bu kayıtlar döndürölmektedir.

Günlük kalori hedefi Harris-Benedict denklemine PAL (Fiziksel Aktivite Düzeyi) çarpanı uygulanarak belirlenmektedir: Bazal Metabolizma Hızı (BMH) erkekler için $88,36 + 13,40 \times kg + 4,80 \times cm - 5,68 \times yaş$; bu deęer hareketsiz yaşam tarzı için 1,2, orta düzey aktif için 1,55 ve çok aktif için 1,9 ile çarpılmaktadır. nutrition/tracker.py, kullanıcının profiline baęlı hedef kaloriyi JSON tabanlı günlük log sistemiyle karşılaştırarak anlık tüketim, kalan kalori ve makro (protein/karbonhidrat/yaę) dağılımını ekranda göstermektedir. Log dosyası kullanıcı_verisi/nutrition_logs.json adresinde profil adı ve tarih anahtarıyla sözlük yapısında saklanmaktadır; bu yapı farklı kullanıcıların verilerinin karışmamasını garantilemektedir.

4.6.4. İlerleme Kaydedicisi

progress/tracker.py modülü kullanıcının antrenman geçmişini, vücut ölçümlerini ve güç değerlerini seans bazında kaydeden hafif bir JSON veri tabanı işlevi görmektedir. Kullanici_verisi/progress_log.json dosyasının yapısı üç alt kategoriden oluşmaktadır: "exercise" girdileri egzersiz kimliği, tekrar sayısı ve seans süresi; "body" girdileri vücut yağ oranı, kilo ve BKİ; "strength" girdileri squat, bench ve deadlift kilogramları ile hesaplanan Dots skoru. Her girdiye otomatik olarak ISO 8601 formatında tarih damgası eklenmektedir. Bu yapı sayesinde kullanıcı uygulama üzerinden haftalık ve aylık trendleri görselleştirilebilmektedir.

İlerleme ekranı (progress/screen.py), son 30 günün egzersiz geçmişini tablo biçiminde listelemekte; güç seyrini grafik yerine satır bazında kıyaslama olarak sunmaktadır. Veri depolama için harici bir veritabanı seçilmemesinin temel nedeni kurulum bağımlılığını sıfırda tutmaktır; SQLite'ın hafif yapısına karşın standart Python kurulumunda hazır bulunan json modülü tercih edilmiştir. Bellek kullanımı açısından ortalama 10 farklı kullanıcı için bir yıllık log yaklaşık 120 KB yer kaplamaktadır.

4.6.5. Kullanıcı Profil Sistemi

Tüm kişiselleştirilmiş hesaplamalar — vücut yağ tahmini, Dots persentili, kalori hedefi — kullanıcı_verisi/profiles.json dosyasına kaydedilen profil üzerine oturmaktadır. Her profil girişi şu alanları içermektedir: ad, boy_cm, kilo_kg, yaş, cinsiyet, bel_cm, kalça_cm, göğüs_cm, kol_cm, boyun_cm. Bel ve kalça gibi çevre ölçümleri opsiyoneldir; girilmediğinde model SimpleImputer aracılığıyla bu alanları popülasyon medyanıyla tamamlar. Sistem çok kullanıcılı çalışmayı desteklemektedir; farklı profiller birbirinin verisine erişemez ve kendi günlüklerine ayrı ayrı yazar. Uygulama açılışında profiles.json okunarak profil listesi gösterilmekte; seçim 2 saniyelik klavye veya el jesti (GestureWorker) ile yapılabilir.

4.6.6. Kullanıcı Arayüzü ve Geri Bildirim Katmanı

Kullanıcı arayüzü 1280×720 kamera görüntüsü üzerine bindirilen dört panelden oluşmaktadır. feedback/visual_feedback.py içindeki draw_hud() işlevi her kare işlendikten sonra çağrılarak iskelet üzerine bu dört bilgi katmanını çizer. Sesli geri bildirim modülü (audio_feedback.py) winsound.Beep() üzerine inşa edilmiş olup üç farklı frekans kullanmaktadır: 800 Hz hata bildirimi, 1.200 Hz uyarı ve 1.600 Hz başarılı tekrar onayı için ayrılmıştır. Birden fazla hatanın aynı anda üst üste gelmesini engellemek amacıyla 1,5 saniyelik cooldown mekanizması uygulanmıştır; bu süre içinde gelen ikinci uyarı sessize alınmakta ve yalnızca görsel panel

güncellenmektedir. HUD düzeni Şekil 3'te gösterilmektedir.

SOL ÜST Açı Göstergesi (8 eklem açısı, faz: UP/DOWN)	SAG ÜST Oturum İstatistikleri (rep sayısı, süre, son ML skoru)
← KAMERA GÖRÜNTÜSÜ (1280×720) — MediaPipe iskelet üst katman →	
SOL ALT Hata/Uyarı Listesi (kırmızı=hata, turuncu=uyarı)	SAG ALT ML Tahmini (confidence %, correct/wrong)

Şekil 3. HUD ekranı dört panel düzeni (1280×720 üzerine OpenCV katmanı)

5. BULGULAR

5.1. Veri Seti İstatistikleri

652 egzersiz videosunun işlenmesi sonucunda 19 egzersiz kategorisinde toplam 1.139 etiketli tekrar elde edilmiştir. Video başına ortalama 1,75 tekrar, seanslardaki video süreleri ve kamera açısı çeşitliliğiyle açıklanabilmektedir. Standart dizüstü bilgisayarda 652 videonun tümü yaklaşık 14 saatte tamamlanmıştır.

Tablo 3. Egzersiz başına veri seti istatistikleri

Egzersiz	Doğru	Yanlış	Toplam	Oran (D/Y)
bench_press	22	10	32	2,2
biceps_curl	32	10	42	3,2
deadlift	27	19	46	1,4
decline_bench_press	15	40	55	0,4
fly	42	8	50	5,3
hammer_curl	28	33	61	0,8
hip_thrust	52	8	60	6,5
incline_bench_press	14	53	67	0,3
lat_pulldown	13	21	34	0,6
lateral_raise	59	29	88	2,0
leg_extension	33	26	59	1,3
leg_raises	34	21	55	1,6
pull_up	46	24	70	1,9
romanian_deadlift	28	23	51	1,2
shoulder_press	5	56	61	0,1
squat	83	7	90	11,9
t_bar_row	82	5	87	16,4
tricep_dips	29	65	94	0,4
triceps	11	26	37	0,4
TOPLAM	655	484	1.139	1,4

5.2. Model Performans Sonuçları

Her egzersiz için eğitilen 19 Random Forest modeli, stratifiye yüzde 80/20 bölünmesiyle elde edilen test kümelerinde değerlendirilmiştir.

Tablo 4. Egzersiz modeli test doğrulukları

Egzersiz	Test Doğruluğu (%)	Test Örneği
bench_press	100,0	6
biceps_curl	88,9	9
deadlift	50,0	9
decline_bench_press	90,9	11
fly	70,0	10
hammer_curl	38,5	13
hip_thrust	91,7	12
incline_bench_press	78,6	14
lat_pulldown	71,4	7
lateral_raise	72,2	18
leg_extension	83,3	12
leg_raises	90,9	11
pull_up	57,1	14
romanian_deadlift	45,5	11
shoulder_press	92,3	13
squat	100,0	18
t_bar_row	88,9	18
tricep_dips	73,7	19
triceps	62,5	8
Ortalama	76,1	—

Sonuçlar üç grupta incelenebilir. Yüksek doğruluk grubu (≥ 85): bench_press, biceps_curl, decline_bench_press, hip_thrust, leg_raises, shoulder_press, squat, t_bar_row. Orta doğruluk grubu (60-84): fly, incline_bench_press, lat_pulldown, lateral_raise, leg_extension, pull_up, tricep_dips, triceps. Düşük doğruluk grubu (< 60): deadlift, hammer_curl, romanian_deadlift.

Özellik önem sıralamaları incelendiğinde tüm egzersiz modellerinde ortaklaşan örüntüler dikkat çekmektedir. Birincil açının standart sapması ve ROM özelliklerinin önem skorları büyük çoğunlukta ilk üçe girmektedir; "hangi açıda olduğundan çok ne kadar tutarlı ve tam hareket edildiği" form kalitesini daha iyi tahmin etmektedir. Başlangıçta en yüksek doğruluğun bilateral egzersizlerden geleceği öngörülmüştü; ancak bench_press ve squat'ın %100 elde ederken fly'ın yalnızca %70 alması bu beklentiyi kısmen tersine çevirdi. Fly egzersizinin görece düşük performansı, iki bilek arası açıyı ölçen özellik vektörünün gövde öne eğimi kaynaklı artefaktlara beklenenden daha kırılgan olduğuna işaret etmektedir.

Çapraz doğrulama (5-kat stratifiye CV) ortalama skoru yüzde 72,4 olarak ölçülmüştür; bu değer test kümesi sonucundan 3,7 puan düşüktür ve aralarındaki fark, veri setinin sınırlı büyüklüğünden kaynaklanan değerlendirme varyansını yansıtmaktadır.

5.3. Sistem Performansı

Intel Core i5-1135G7 (entegre Iris Xe grafik) işlemcili 16 GB RAM'li dizüstü bilgisayarda test edilmiştir. MediaPipe model_complexity=0 ile 480×270 çözünürlükte ortalama 28-32 fps elde edilmiştir. Aynı donanımda 1280×720 çözünürlükte doğrudan pose işleme yapıldığında kare hızı 10-14 fps'ye gerilemiştir; bu nedenle düşük çözünürlük-yüksek ekran ayrımı zorunlu kılınmıştır. Bellek kullanımı: başlangıçta yaklaşık 380 MB, 19 model yüklenince yaklaşık 450 MB.

5.4. Vücut Yağ ve Güç Profili Değerlendirmesi

Vücut yağ tahmini modülü dört farklı kullanıcıyla (Furkan, İslam, Mustafa, Yusuf) toplam 12 ölçüm seansında değerlendirilmiştir. Kamera mesafesi 1,5-2,5 m aralığında tutulmuş; her kullanıcı için üç tekrar ölçüm gerçekleştirilmiştir. Sonuçlar incelendiğinde aynı kullanıcı için yağ tahmini değerleri $\pm 2,1$ yüzde puan standart sapma göstermiştir. Bu değer, deri kıvrımı ölçüm yöntemiyle elde edilen günler arası tekrarlanabilirliğe ($\pm 3,5$) ve BKİ tabanlı tahminlere ($\pm 4,8$) kıyasla belirgin biçimde daha kararlı bir seyir izlemiştir. Ancak bu karşılaştırmanın sınırlılığı vurgulanmalıdır: klinik doğrulama için DXA veya su altı tartımı referans alınmamış; sistematik sapma (bias) hesaplanmamıştır. Modelin eğitildiği veri setinde ağırlıklı ABD popülasyonu yer aldığından Türk kullanıcılar için kalibrasyon hatası beklenenden yüksek olabilir.

Güç profili değerlendirmesinde dört kullanıcının squat, bench press ve deadlift değerleri sisteme girilmiştir. Örnek olarak Furkan profili (70 kg, 178 cm, 23 yaş) için

sisteme girilen 150/150/200 kg kaldırıřlar Dots skoru 375,6 olarak hesaplanmıř; bu deęer OpenPowerlifting norm tablosunda yzde 95 persentile karřılık gelmektedir. Yusuf profili (85 kg) iin 130/110/160 kg giriřinden Dots skoru 266,5 elde edilmiř ve bu deęer yaklařık yzde 72 persentile dřmřtr. Norm tablosunun gerek yarıřma verilerine dayandıęı dřnldęnde bu ıktıların yorumlanmasında dikkatli olunmalıdır; antrenman řartlarında llen kaldırıřlar genellikle yarıřma kaldırıřlarından dřk ıkmakta, dolayısıyla kullanıcı persentili gerek rekabeti dzeyinden hafif yukarıda grnebilmektedir. Bu durum kullanıcıya ilerleme baęlamında motivasyon saęlayıcı bir referans sunarken kıyaslamanın yarıřma performansıyla doęrudan rtřmedięi not edilmelidir.

6. TARTIŞMA VE SONUÇ

6.1. Bulgular Üzerine Değerlendirme

Ortalama yüzde 76,1 test doğruluğu, ne mükemmel bir başarı ne de açık bir başarısızlık olarak nitelendirilebilir; bu sayının anlamını veri hacmi ve metodolojik kısıtlamalar çerçevesinde yorumlamak gerekmektedir. Egzersiz başına ortalama 60 etiketli tekrar, akademik makine öğrenmesi çalışmalarında "az veri" kategorisine girmektedir. Bununla birlikte mevcut sistem, bu sınırla birlikte bile egzersizlerin üçte ikisinde yüzde 70'in üzerinde doğruluk elde etmekte; bu oran, teknik fizibilite hedefi için yeterli kabul edilebilmektedir.

Shoulder_press'in yüzde 92,3 doğruluğuyla yüksek performanslı görünmesi ancak 5 doğru/56 yanlış oranına sahip olması, sınıf önyargısı sorununu açıkça ortaya koymaktadır. Model neredeyse her durumda "yanlış" tahmin ederek yüksek doğruluk elde etmektedir. Hammer_curl (yüzde 38,5), romanian_deadlift (yüzde 45,5) ve deadlift (yüzde 50,0) için zayıf sonuçlar ise kural motoru ile gerçek form kalitesi arasındaki uyum düşüklüğünü yansıtmaktadır.

6.2. Literatürle Karşılaştırma

Liao vd. (2020) ile doğrudan karşılaştırma yapılabilmektedir: onlar yalnızca squat egzersizini ve 8 katılımcıyı kullanarak yüzde 85 uyum bildirmiştir. Bu çalışma 19 egzersiz ve 1.139 tekrarla yüzde 76,1 ortalama elde etmiştir. Sayısal açıdan bakıldığında bu bir gerileme gibi görünse de kapsam on dokuz kat daha geniş ve veri tamamen otomatik etiketlenmiştir; insan doğrulaması yapılmamıştır. KIMORE tabanlı çalışmalar yüzde 80-90 aralığında raporlamaktadır ama koşullar çok daha kontrollüdür: Kinect derinlik sensörü, sabit ışıklı laboratuvar ortamı, beş egzersiz ve klinik fizyoterapist denetimi. Ev ortamı tek kamera senaryosunda bu rakamları doğrudan kıyaslamamak gerekir.

6.3. Sınırlılıklar

En büyük sorun veri hacmidir. Egzersiz başına ortalama 60 tekrar makine öğrenmesi literatüründe "az veri" sayılır; pek çok modelin yüzde 70'in altında kalması, daha fazla verinin toplanmasını gerektirdiğini göstermektedir. İkinci sorun etiketleme döngüsüdür: etiketler kural motorlarına dayanıyor, kural motorları ise araştırmacı kararlarına. Bu durum hatanın veri setine taşınması anlamına gelir ve en iyi makine öğrenmesi modelinin dahi performansını tavan düzeyinde kısıtlar. Üçüncü sorun klinik doğrulama yapılamamış olmasıdır; bildirilen doğruluklar kendi veri setimiz

üzerinde hesaplanmış, bağımsız katılımcı testleriyle teyit edilmemiştir. Son olarak tek kamera kısıtlı bazı üç boyutlu hataları — örneğin diz içe çökmesini — sagittal düzlemde görülemeyen açılar nedeniyle kaçırabilmektedir.

6.4. Gelecek Çalışmalar

Kısa vadede öncelikli iyileştirme hedefi etiketleme kalitesini artırmaktır. İnsan etiketlemesi ve Cohen's Kappa uyum ölçümü eklenebilir. Orta vadede LSTM ya da Temporal Convolutional Network (TCN) tabanlı zaman serisi modelleri tekrar içindeki zamansal bağımlılıkları daha iyi yakalayabilir. Uzun vadede üç boyutlu landmark koordinatları açı hesabına dahil edilebilir, mobil platformlara taşınabilir ve rehabilitasyon alanına genişlenebilir.

6.5. Sonuç

Bu çalışmada, kullanıcılara kişisel antrenöre başvurmadan gerçek zamanlı egzersiz form geri bildirimi sağlayan, veri odaklı ve çok modüllü bir bilgisayarlı görüş platformu tasarlanmış ve Python ekosistemi üzerinde çalışır hâle getirilmiştir. Sistemin teknik omurgası: BlazePose tabanlı 33 noktalı iskelet çıkarımı, sekiz temel eklem açısının gerçek zamanlı hesabı, 19 egzersiz için biyomekanik kural motorları, 40 boyutlu özellik vektörü üzerinde Random Forest sınıflandırıcıları ve çok iş parçacıklı mimari. 652 YouTube videosunu işleyerek 1.139 etiketli tekrar üreten otomatik pipeline, vücut yağ tahmini, güç persentili ve Türkiye'ye özgü beslenme takibiyle bütüncül bir performans rehberliği sunmaktadır. Ortalama yüzde 76,1 test doğruluğuyla teknik fizibilite düzeyini karşılamakta; gelecekte insan etiketlemesi ve zamansal modellerin entegrasyonu ile geliştirilmeye açık, ölçeklenebilir bir temel oluşturmaktadır.

KAYNAKÇA

- Bazarevsky, V., Grishchenko, I., Raveendran, K., Zhu, T., Zhang, F. ve Grundmann, M. (2020). BlazePose: On-device real-time body pose tracking. Retrieved from <https://arxiv.org/abs/2006.10204>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Cao, Z., Hidalgo, G., Simon, T., Wei, S. E. ve Sheikh, Y. (2021). OpenPose: Realtime multi-person 2D pose estimation using part affinity fields. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(1), 172–186.
- Capecci, M., Ceravolo, M. G., Ferracuti, F., Iarlori, S., Monteriu, A., Romeo, L. ve Verdini, F. (2018). The KIMORE dataset. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 27(7), 1436–1448.
- Dang, Q., Yin, J., Wang, B. ve Zheng, W. (2022). Deep learning based 2D human pose estimation: A survey. *Tsinghua Science and Technology*, 24(6), 663–676.
- Durnin, J. V. G. A. ve Womersley, J. (1974). Body fat assessed from total body density and its estimation from skinfold thickness. *British Journal of Nutrition*, 32(1), 77–97.
- EuropeActive. (2022). European health & fitness market report 2022. EuropeActive Publications.
- Jackson, A. S. ve Pollock, M. L. (1978). Generalized equations for predicting body density of men. *British Journal of Nutrition*, 40(3), 497–504.
- Kerr, Z. Y., Collins, C. L. ve Comstock, R. D. (2010). Epidemiology of weight training-related injuries. *American Journal of Sports Medicine*, 38(4), 765–771.
- Kok, M., Hol, J. D. ve Schoen, T. B. (2022). An automated physical therapy exercise assessment using pose estimation. *Sensors*, 22(12), 4584.
- Krizhevsky, A., Sutskever, I. ve Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- Liao, Y., Vakanski, A. ve Xian, M. (2020). A deep learning framework for assessing physical rehabilitation exercises. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 28(2), 468–477.

- Lugaresi, C., Tang, J., Nash, H., McClanahan, C., Ubowejr, E., Hock, C. ve Grundmann, M. (2019). MediaPipe: A framework for building perception pipelines. Retrieved from <https://arxiv.org/abs/1906.08172>
- Newell, A., Yang, K. ve Deng, J. (2016). Stacked hourglass networks for human pose estimation. In B. Leibe, J. Matas, N. Sebe ve M. Welling (Eds.), *Computer Vision – ECCV 2016* (s. 483–499). Springer.
- OpenPowerlifting. (2023). OpenPowerlifting database. Retrieved from <https://www.openpowerlifting.org/>
- Pirsiavash, H. ve Ramanan, D. (2014). Assessing the quality of actions. In D. Fleet, T. Pajdla, B. Schiele ve T. Tuytelaars (Eds.), *Computer Vision – ECCV 2014* (s. 556–571). Springer.
- Shotton, J., Fitzgibbon, A., Cook, M., Sharp, T., Finocchio, M., Moore, R., Kipman, A. ve Blake, A. (2011). Real-time human pose recognition in parts from single depth images. 2011 IEEE Conference on Computer Vision and Pattern Recognition (s. 1297–1304). IEEE.
- Sun, K., Xiao, B., Liu, D. ve Wang, J. (2019). Deep high-resolution representation learning for visual recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(10), 3349–3364.
- U.S. Centers for Disease Control and Prevention. (2023). National Health and Nutrition Examination Survey (NHANES). Retrieved from <https://www.cdc.gov/nchs/nhanes/>
- U.S. Army Research Laboratory. (2012). Anthropometric Survey of U.S. Army Personnel: Methods and Summary Statistics (ANSUR II). Defense Technical Information Center.

EKLER

Ek A. Sistem Modül Yapısı

Proje kök dizininde ana bileşenler: main.py, pose_detector.py, gesture_detector.py, config.py, profiles.py. Alt dizinler ve işlevleri:

Dizin	İşlev
exercises/	19 egzersiz analiz motoru; BaseExercise soyut sınıfı
ml/	Form sınıflandırıcı, video madenci, model eğitici, veri toplayıcı
bodyfat/	Vücut yağ tahmini; silüet ve antropometri entegrasyonu
strength/	OpenPowerlifting normları; Dots skoru hesaplayıcı
nutrition/	Türk gıda veritabanı; kalori hedef hesaplayıcı
progress/	Seans bazlı ilerleme kaydedicisi; JSON saklama
feedback/	HUD (visual_feedback.py); ses sistemi (audio_feedback.py)
utils/	Açı ve mesafe hesaplayıcı; landmark dönüşüm araçları
tools/	Toplu video işleyici; pipeline; sentetik veri üretici

Ek B. Kullanılan Kütüphaneler

Kütüphane	Sürüm	Kullanım Amacı
mediapipe	>= 0.10.0	İskelet çıkarımı, segmentasyon, el jesti
opencv-python	>= 4.8.0	Kamera akışı, HUD çizimi
scikit-learn	>= 1.3.0	RandomForest, GradientBoosting, StandardScaler
numpy	>= 1.24.0	Açı hesaplama, istatistik
pandas	>= 2.0.0	CSV yönetimi, veri analizi
joblib	scikit-learn ile	Model kaydetme/yükleme (.joblib)
yt-dlp	Son sürüm	YouTube video indirme

Ek C. Temel Konfigürasyon Parametreleri

config.py'de tanımlanan kritik sabitler: CAMERA_WIDTH=1280, CAMERA_HEIGHT=720; PROCESS_WIDTH=480, PROCESS_HEIGHT=270; MIN_VISIBILITY=0.40; AUDIO_COOLDOWN=1.5 sn; CORRECT_RATIO_THRESHOLD=0.60; ML_CONFIDENCE_THRESHOLD=0.55;

MIN_SAMPLES_PER_CLASS=5; RF_N_ESTIMATORS=300; MIN_SAMPLES_LEAF=3;
BF_BUFFER_SIZE=25 (vücut yağ ölçüm kare ortalaması).